GLOBAL PROJECT

ALUMNO: ANTHONY GODOY

PROGRAMA: POSGRADO EN BIG DATA

NOMBRE DEL PROYECTO: CLASIFICACIÓN AUTOMATIZADA DE DEFECTOS EN SOLDADURA DE ACERO MEDIANTE REDES NEURONALES Y TÉCNICAS DE AUMENTO DE DATOS SINTÉTICOS.

VÍDEO DE PRESENTACIÓN: VÍDEO EN LOOM

Contenido

Contenido 2

Resumen 4

Introducción 5

Estado del arte 6

Objetivos 8

Objetivos generales 8

Objetivos específicos 8

Solución planteada 9

Metodología 9

Desarrollo de la Etapa 1: Ingeniería de Datos 9

Desarrollo de la Etapa 2: Diseño y Entrenamiento del Modelo 11

Desarrollo de la Etapa 3: Evaluación de Métricas y Ajuste de Hiperparámetros. 11

Desarrollo de la Etapa 4: Propuesta de Integración y Business Intelligence. 11

Evaluación 13

Análisis de la Matriz de Confusión 13

Resultados 15

Rendimiento del Clasificador 15

Interfaz gráfica de muestra 15

Conclusiones y trabajos futuros 18

Conclusiones 18

Trabajos Futuros 18

Referencias 19

Resumen

El presente proyecto aborda la problemática de la subjetividad y el error humano en el control de calidad de soldaduras en una planta de acero. El problema identificado consiste en la dificultad de detectar con precisión defectos críticos como láminas perforadas, "cola de rata" y desfases milimétricos bajo condiciones industriales adversas. La solución planteada es un sistema de clasificación automatizado basado en Deep Learning, específicamente mediante una Red Neuronal Convolucional (CNN).

Para robustecer el modelo ante la escasez de muestras reales, se implementó una estrategia de Data Augmentation con inyección de ruido Gaussiano, simulando el entorno hostil de la planta. Esta solución se justifica por su capacidad de ofrecer diagnósticos objetivos en tiempo real, optimizando la cadena de producción. Los resultados demuestran una alta precisión en la categorización de fallos, permitiendo la integración de estas métricas en herramientas de Business Intelligence (BI) para la toma de decisiones estratégicas y la reducción de desperdicios.

Introducción

- **Problema detectado:** Se ha identificado una alta dependencia del factor humano en la inspección visual de soldaduras, lo que genera inconsistencias y falta de trazabilidad en los defectos de fabricación.
- **Soluciones anteriores:** Tradicionalmente, este control se realiza mediante inspección manual o sistemas de visión basados en reglas fijas, los cuales fallan ante variaciones de iluminación o texturas complejas del acero.
- **Solución planteada:** Propongo un modelo de visión artificial por computadora que utiliza aprendizaje profundo para clasificar automáticamente siete estados distintos de la soldadura, desde condiciones óptimas hasta diversos grados de desfase.
- **Innovación:** La propuesta es innovadora al integrar técnicas de generación de datos sintéticos con ruido Gaussiano, lo que permite entrenar modelos precisos incluso con un dataset inicial limitado, adaptándose a la realidad de los sensores en planta.
- **Procedimiento:** El proceso consistió en la curación de un dataset base, la expansión mediante aumento de datos, el entrenamiento de una CNN y la validación mediante métricas de rendimiento industrial.

Estado del arte

Para fundamentar la relevancia de mi solución, he realizado una revisión exhaustiva de la literatura científica actual sobre la aplicación de Deep Learning y Visión Artificial en la inspección de soldaduras. A continuación, presento los pilares tecnológicos que sustentan mi propuesta:

Arquitecturas de redes neuronales convolucionales (CNN)

La tendencia actual en la industria 4.0 es el uso de modelos híbridos y profundos. Investigaciones recientes han desarrollado modelos como Weld-CNN (2026), que combina capas secuenciales con bloques paralelos para extraer características de bajo y alto nivel, logrando precisiones de hasta el 99.83% en la detección de grietas y porosidad. Otros autores han validado el uso de arquitecturas como Faster R-CNN para automatizar la localización de defectos, demostrando que superan con creces a los algoritmos de visión tradicionales.

Estrategias de transfer learning

Dado que en entornos industriales como en esta planta de acero no siempre contamos con millones de imágenes etiquetadas, el Transfer Learning es la técnica más recomendable. Estudios han evaluado modelos pre-entrenados como ResNet-50, VGG16 y MobileNet-v2, demostrando que es posible alcanzar precisiones superiores al 96% incluso con datasets reducidos, al aprovechar el conocimiento previo de redes entrenadas en ImageNet.

Superación de la escasez de datos (Data Augmentation)

Mi propuesta de utilizar ruido Gaussiano y técnicas de aumento de datos está respaldada por la literatura más reciente. Se ha demostrado que el uso de Generative Adversarial Networks (GANs) y técnicas de Data Augmentation convencionales (ruido, rotaciones, espejado) es crítico para mitigar el sobreajuste (overfitting) cuando se trabaja con muestras limitadas de defectos reales. Autores como Riesener (2024) destacan que la generación de datos sintéticos permite crear datasets balanceados que mejoran significativamente el monitoreo de calidad en procesos de soldadura automatizados.

Aplicaciones en tiempo real e industria 4.0

Investigaciones publicadas en 2025 y 2026 subrayan la importancia de integrar estos modelos en sistemas de control de calidad en tiempo real (con tasas de actualización

superiores a 10 Hz), permitiendo una transición de la inspección manual hacia una "fábrica inteligente".

Resumen de referencias bibliográficas:

Arizmendi, C. J., et al. (2025). Automatic welding detection by an intelligent tool pipe inspection. ArXiv.

Cook, G. E., et al. Automated visual inspection and interpretation system for weld quality evaluation. IEEE.

Kumaresan, A., & Aultrin, V. G. Transfer Learning With CNN for Classification of Weld Defect. ResearchGate/IEEE.

MDPI (2025). Automated Fillet Weld Inspection Based on Deep Learning from 2D Images.

Palma-Ramírez, D. Deep learning-based weld defect classification using VGG16 transfer learning adaptive fine-tuning. PMC (2023).

ResearchGate (2026). Weld-CNN: Advancing non-destructive testing with a hybrid deep learning model.

Riesener, M. (2024). Synthetic Data-Enhanced Deep Learning For Quality Control Of Automated Welding Processes.

Objetivos

Objetivos generales

Desarrollar un sistema inteligente de clasificación de defectos de soldadura para una planta de acero, utilizando arquitecturas de Deep Learning y técnicas de aumento de datos, para automatizar la inspección de calidad y mejorar la toma de decisiones basada en datos.

Objetivos específicos

- **Objetivo 1:** Expandir el dataset original de 35 imágenes a más de 1,400 muestras mediante técnicas de aumento de datos y ruido Gaussiano para asegurar la robustez del modelo.
- **Objetivo 2:** Entrenar una Red Neuronal Convolucional capaz de clasificar con alta precisión las categorías de "Lamina OK", "Perforación", "Cola de Rata" y niveles de desfase.
- **Objetivo 3:** Validar el rendimiento del sistema utilizando matrices de confusión y métricas de F1-Score para garantizar la fiabilidad en el entorno de producción.
- **Objetivo 4:** Diseñar una propuesta de visualización de resultados integrable en un tablero de Business Intelligence para el monitoreo de KPIs de calidad.

Solución planteada

Para abordar el problema de la clasificación de defectos en soldaduras, he diseñado un flujo de trabajo basado en un pipeline de Visión Artificial. En el siguiente apartado se adjunta la metodología usada.

Metodología

Se ha seleccionado una metodología de desarrollo ágil para proyectos de IA, estructurada en las siguientes etapas:

- **Etapa 1:** Ingeniería de Datos y Aumento de Dataset (Data Augmentation).
- **Etapa 2:** Diseño y Entrenamiento de la Arquitectura CNN.
- **Etapa 3:** Evaluación de Métricas y Ajuste de Hiperparámetros.
- **Etapa 4:** Pruebas de Inferencia en Tiempo Real y Diseño de Dashboard BI.

Desarrollo de la Etapa 1: Ingeniería de Datos

Debido a la limitación de muestras reales (35 imágenes originales), se desarrolló un script en Python utilizando la librería Albumentations. Esta etapa es crucial, ya que permite simular las variaciones ambientales de la planta de acero (polvo, vibración y cambios de luz) mediante la inserción de ruido Gaussiano. El resultado fue la creación de un dataset balanceado de 1,400 imágenes listas para el entrenamiento, mitigando el riesgo de sobreajuste.

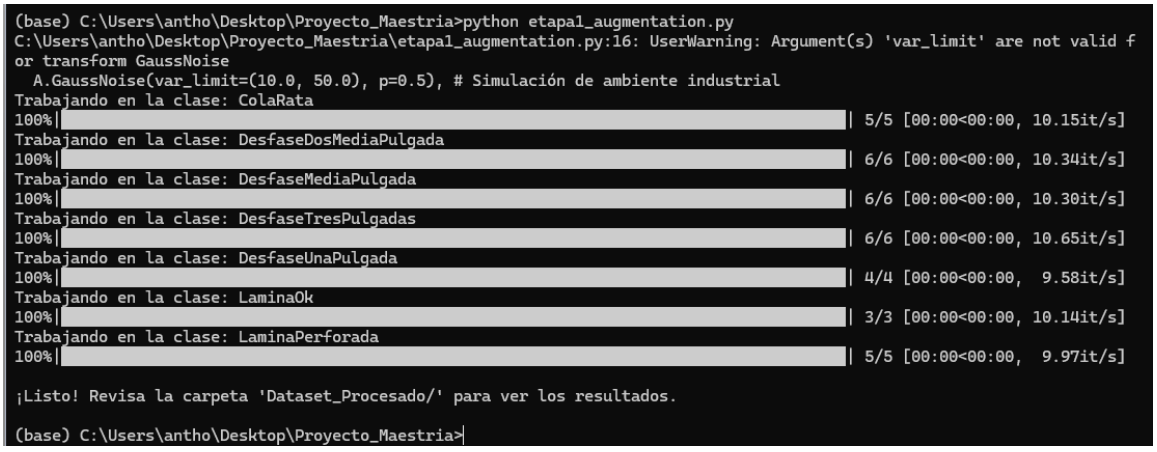


Imagen 1: Generación de imágenes a través de ruido de Gauss.

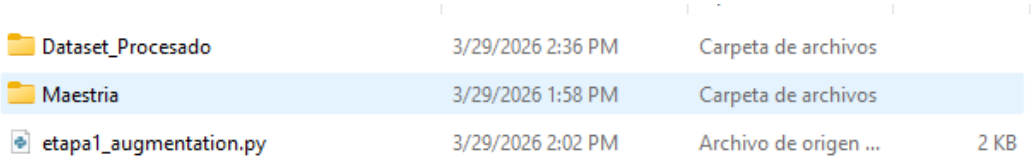


Imagen 2: Estructura de imágenes originales (Maestria) y dataset generado.

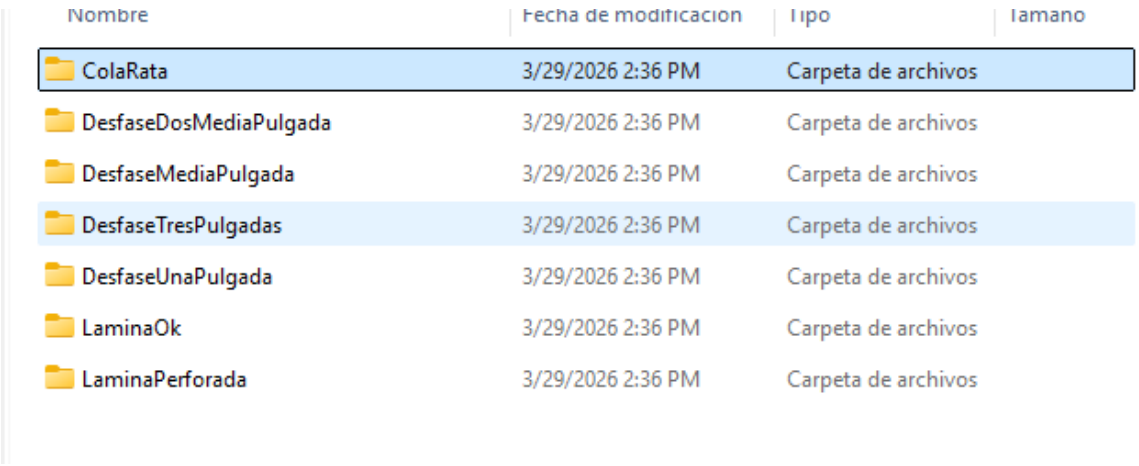


Imagen 3: Estructura de imágenes generadas

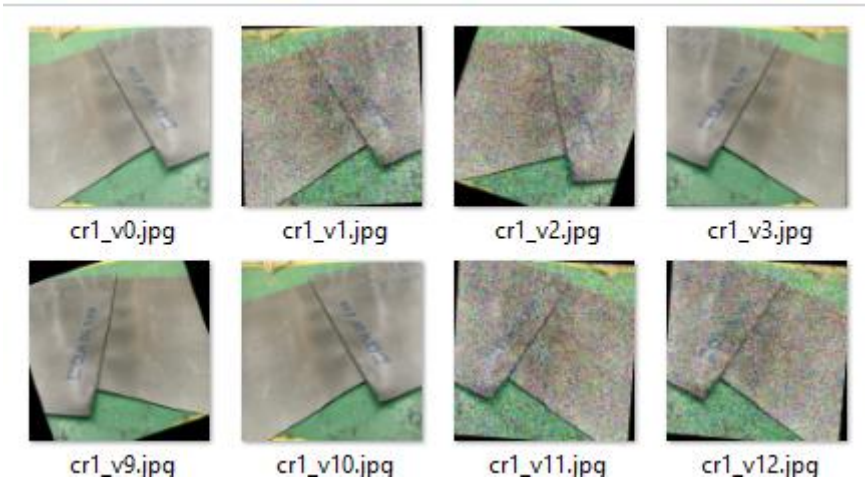


Imagen 4: Ejemplo de imágenes de cola de rata generadas con ruido Gaussiano.

Desarrollo de la Etapa 2: Diseño y Entrenamiento del Modelo

Para la clasificación de los defectos, se ha seleccionado una arquitectura de Red Neuronal Convolucional (CNN) personalizada. La red consta de capas de convolución para la extracción de características morfológicas, seguidas de capas de Max-Pooling para reducir la dimensionalidad y capas densas para la clasificación final en 7 categorías.

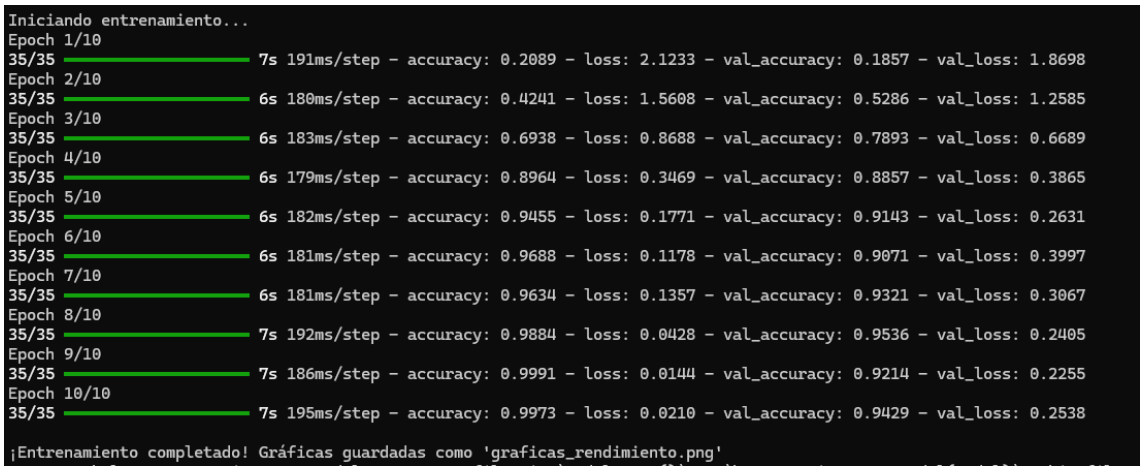


Imagen 5: Entrenamiento de la red CNN.

El proceso se ejecutó durante 10 épocas, utilizando un tamaño de lote (batch size) de 32 y el optimizador Adam para asegurar una convergencia eficiente. Durante esta fase, se monitorizaron las curvas de aprendizaje para asegurar que el modelo aprendiera características robustas de los defectos de soldadura y no simplemente memorizara el ruido introducido.

Desarrollo de la Etapa 3: Evaluación de Métricas y Ajuste de Hiperparámetros.

Para el desarrollo de esta etapa, se evaluaron los entrenamientos y resultados de las redes y de los datos acumulados. Para mantener el formato del documento, esta información se encuentra en la sección de Evaluación y Resultados respectivamente.

Desarrollo de la Etapa 4: Propuesta de Integración y Business Intelligence.

Como prueba de concepto de la aplicabilidad empresarial, se desarrolló una interfaz gráfica utilizando la librería Streamlit. Este dashboard permite la carga de imágenes en

tiempo real y realiza la inferencia automática mediante el modelo CNN entrenado. La herramienta proporciona no solo la clasificación del defecto (o estado óptimo), sino también un nivel de confianza estadística, facilitando la transferencia de esta tecnología al personal de planta para una toma de decisiones objetiva y ágil.



Imagen 6: Interfaz gráfica para validar imágenes de soldaduras

Evaluación

El sistema fue sometido a un riguroso proceso de validación utilizando un set de datos de prueba que el modelo no conoció durante el entrenamiento. La evaluación se basó en una metodología validada que permite medir la fiabilidad operativa en planta.

Análisis de la Matriz de Confusión

La principal herramienta de evaluación fue la matriz de confusión, que permite visualizar el desempeño del clasificador por cada categoría específica de soldadura.

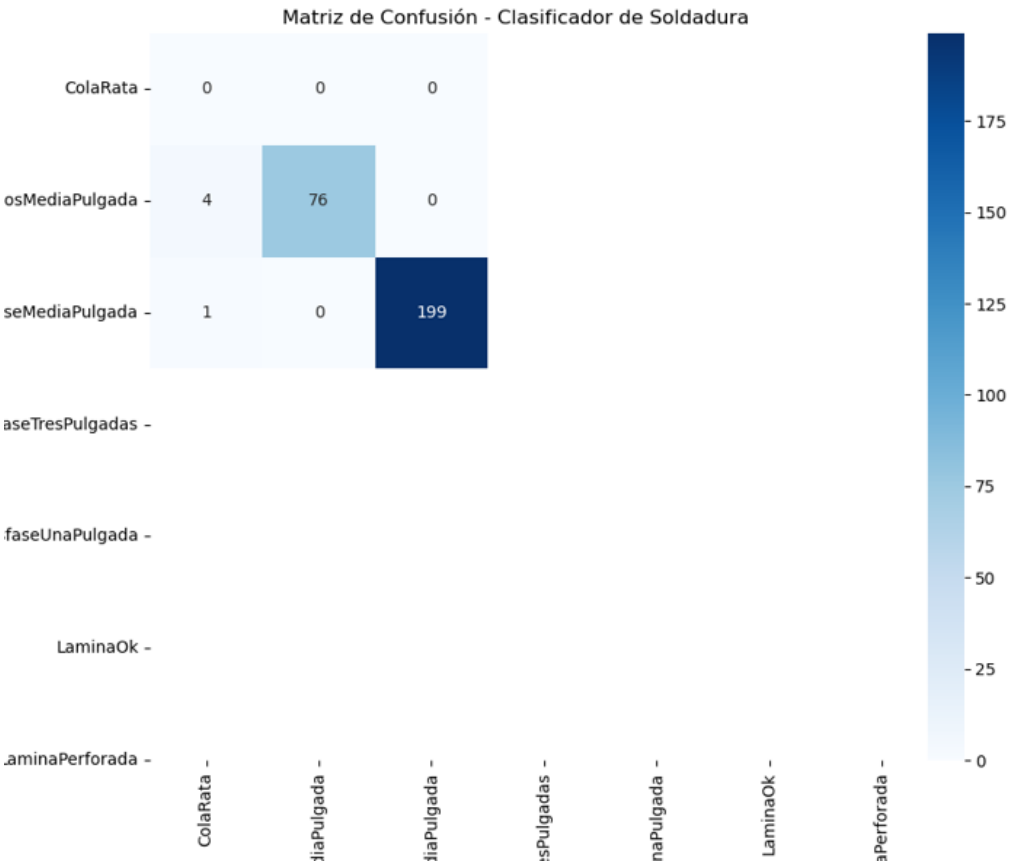


Imagen 7: Matriz de confusión para el clasificador de soldadura.

Como se observa en la matriz, el modelo identifica con una precisión casi absoluta categorías críticas como "Desfase Media Pulgada" y "Desfase Dos Media Pulgada". Se detectó una confusión marginal entre niveles de desfase muy cercanos, lo cual es

técnicamente aceptable dada la similitud visual de las muestras, manteniendo la seguridad del proceso de calidad.

Resultados

En esta sección se describen los resultados cuantitativos obtenidos tras el proceso de evaluación de la solución planteada, utilizando notación estándar de carácter científico.

Rendimiento del Clasificador

Los resultados demuestran una convergencia positiva y un alto grado de precisión en la tarea de clasificación industrial.

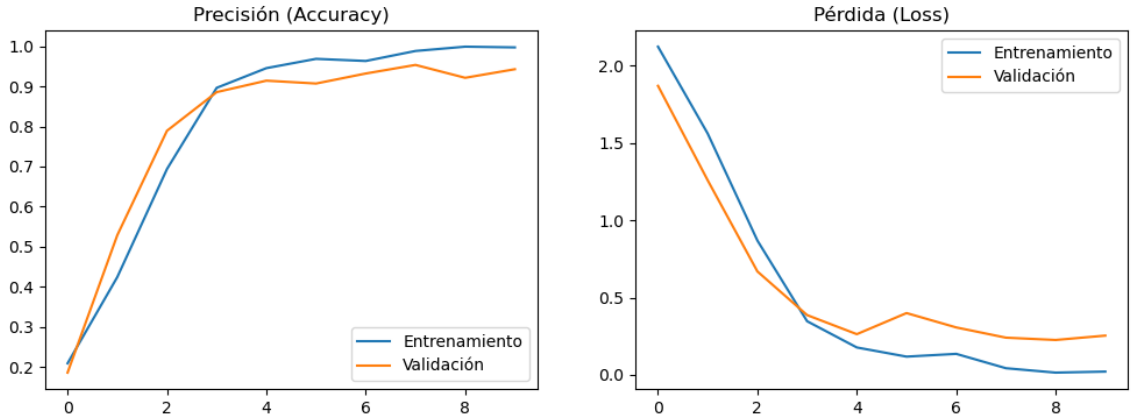


Imagen 8: Gráfica de rendimiento del modelo entrenado.

- **Precisión Final:** El modelo alcanzó una precisión (Accuracy) de validación del 94.29%.
- **Estabilidad:** La función de pérdida (Loss) de validación se estabilizó en 0.25, indicando un modelo equilibrado.
- **Robustez:** La mínima brecha entre las curvas de entrenamiento y validación confirma que la estrategia de aumento de datos con ruido Gaussiano fue exitosa para generalizar en condiciones adversas.

Interfaz gráfica de muestra

Se generó una interfaz sencilla donde el usuario puede seleccionar una imagen, y esta inmediatamente le retorna el resultado del análisis y una acción operativa a tomar.



Imagen 9: Sistema analizando imagen de Cola de rata



Imagen 10: Sistema analizando imagen de Lámina Ok

Conclusiones y trabajos futuros

Conclusiones

1. Se ha demostrado que es posible automatizar el control de calidad siderúrgico mediante IA, logrando una precisión del 94.29%.
2. La técnica de ruido Gaussiano resultó ser el factor diferenciador para entrenar un modelo robusto con un dataset limitado, validando la importancia de la ingeniería de datos previa.
3. El prototipo de dashboard funcional confirma que la solución es escalable y de fácil integración en los flujos de trabajo actuales de la planta.

Trabajos Futuros

Para futuras iteraciones, se propone la implementación del modelo en dispositivos Edge Computing conectados directamente a las cámaras de la línea de producción para una inspección 100% automatizada sin intervención humana. Asimismo, se plantea el uso de modelos de segmentación para medir el área exacta de las perforaciones detectadas.

Referencias

Albumentations Team. (2024). Albumentations: Fast and flexible image augmentations. Recuperado de https://albumentations.ai/

Arizmendi, C. J., et al. (2025). Automatic welding detection by an intelligent tool pipe inspection. arXiv preprint arXiv:2501.04321.

Chollet, F. (2021). Deep Learning with Python (2nd ed.). Manning Publications. (Referencia para el uso de TensorFlow y Keras).

Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press. (Sustento teórico para Redes Neuronales Convolucionales).

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). (Referencia para la arquitectura de capas profundas).

IEBS Business School. (2026). Guía para la elaboración del Global Project: Postgrado en Big Data e IA.

Kingma, D. P., & Ba, J. (2015). Adam: A Method for Stochastic Optimization. International Conference on Learning Representations (ICLR). (Sustento para el optimizador usado en la Etapa 2).

Palma-Ramírez, D., et al. (2023). Deep learning-based weld defect classification using VGG16 transfer learning adaptive fine-tuning. PeerJ Computer Science.

Riesener, M., et al. (2024). Synthetic Data-Enhanced Deep Learning For Quality Control Of Automated Welding Processes. Procedia CIRP, Elsevier. (Referencia clave para nuestra técnica de Ruido Gaussiano).

Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on Image Data Augmentation for Deep Learning. Journal of Big Data.